

Metaheurísticas:  
Práctica 1.b: Búsquedas por Trayectorias para el  
Problema de la Selección de Características

Anabel Gómez Ríos.  
DNI: 75929914Z.  
E-mail: anabelgrios@correo.ugr.es

7 de abril de 2016

Curso 2015-2016  
Problema de Selección de Características.  
Grupo de prácticas: Viernes 17:30-19:30  
Quinto curso del Doble Grado en Ingeniería Informática y Matemáticas.

Algoritmos considerados:

1. Greedy Sequential Forward Selection.
2. Búsqueda Local.
3. Enfriamiento Simulado.
4. Búsqueda Tabú Básica.
5. Búsqueda Tabú Extendida.

# Índice

<b>1. Descripción del problema</b>	<b>3</b>
<b>2. Descripción de la aplicación de los algoritmos empleados al problema</b>	<b>4</b>
2.1. Representación de soluciones . . . . .	4
2.2. 3NN . . . . .	4
2.3. Función de evaluación . . . . .	4
2.4. Operadores comunes: Generación de vecinos . . . . .	5
<b>3. Descripción de los algoritmos</b>	<b>6</b>
3.1. Búsqueda Local . . . . .	6
3.2. Enfriamiento Simulado . . . . .	7
3.3. Búsqueda Tabú Básica . . . . .	8
3.4. Búsqueda Tabú Extendida . . . . .	9
<b>4. Breve descripción del algoritmo de comparación</b>	<b>11</b>
<b>5. Procedimiento considerado para desarrollar la práctica</b>	<b>12</b>
<b>6. Experimentos y análisis de resultados</b>	<b>12</b>
6.1. Descripción de los casos del problema empleados . . . . .	12
6.2. Resultados . . . . .	12
6.3. Análisis de los resultados . . . . .	13
<b>7. Bibliografía</b>	<b>13</b>

# 1. Descripción del problema

Queremos obtener un sistema que permita clasificar un conjunto de objetos en unas determinadas clases que conocemos previamente. Para ello disponemos de una muestra de dichos objetos ya clasificados y una serie de características para cada objeto.

El problema es, por tanto, construir un clasificador que se comporte lo suficientemente bien fuera de la muestra de la que disponemos, es decir, que clasifique bien nuevos datos. Para hacer esto, lo que hacemos es particionar la muestra en dos subconjuntos, uno que utilizaremos de entrenamiento para que el clasificador aprenda y otro que utilizaremos para test, es decir, para ver cómo de bien se comporta el clasificador que hemos obtenido con el primer subconjunto fuera de los datos de entrenamiento. Además haremos distintas particiones, en concreto 5 para mayor seguridad y construiremos un clasificador para cada una de ellas. Podemos comprobar cómo de bien se comporta cada clasificador porque sabemos en todo momento las clases de los objetos que tenemos en la muestra y podemos comparar las verdaderas clases con las que el clasificador obtiene.

Buscamos pues en todo momento optimizar la tasa de acierto del clasificador.

Vamos a utilizar además validación cruzada: es decir, para cada partición en dos subconjuntos primero uno será el de entrenamiento y el otro el de test y después les daremos la vuelta y volveremos a construir un clasificador. La calidad por tanto de cada método será la media de los porcentajes de clasificación (la tasa de acierto) para estas 10 particiones.

Nos queda describir cómo aprende el clasificador con los datos de entrenamiento. Ya que podemos llegar a tener muchas características de las cuales podríamos tener algunas poco o nada significantes, lo que hacemos es elegir un subconjunto de características que describan bien los datos de entrenamiento, de forma que en los datos de test sólo tenemos en cuenta este subconjunto de características a la hora de deducir cuál es la clase de cada nuevo dato. Para esta "deducción" vamos a utilizar la técnica de los 3 vecinos más cercanos: buscamos para cada dato los tres vecinos más cercanos teniendo en cuenta las características seleccionadas hasta el momento y nos quedamos con la clase que más veces aparezca. El cómo exploramos el espacio de búsqueda hasta encontrar la mejor solución (el subconjunto de características óptimo) es en lo que se diferencian los distintos algoritmos que vamos a ver en esta práctica.

## 2. Descripción de la aplicación de los algoritmos empleados al problema

El primer paso común a todos los algoritmos es normalizar los datos de los que disponemos por columnas (es decir, por características) de forma que todas se queden entre 0 y 1 y no haya así preferencias de unas sobre otras.

A continuación se genera una solución inicial, que estará en todos los casos (menos en el algoritmo greedy, que se empieza desde cero) generada aleatoriamente y se irán generando vecinos de esta solución (o se darán saltos, como ya veremos) y nos quedaremos con la mejor solución obtenida.

Todos los algoritmos tienen una condición de parada común, que es llegar a un número máximo de evaluaciones o soluciones generadas: 15000.

### 2.1. Representación de soluciones

La representación elegida para las soluciones ha sido binaria: un vector de  $N$  posiciones, donde  $N$  es el número de características, en el que aparece *True* o *False* en la posición  $i$  según si la característica  $i$ -ésima ha sido seleccionada o no, respectivamente.

### 2.2. 3NN

Como hemos comentado, la técnica para clasificar que vamos a utilizar en todos los algoritmos será el 3NN. Consiste en considerar, para cada dato, la distancia euclídea entre el dato y todos los demás (excluyéndose él mismo en caso de que estuviéramos preguntando por algún dato dentro del conjunto de entrenamiento (leave one out)) y quedarnos con las clases de los 3 con la distancia más pequeña. La clase del dato en cuestión será de estas tres la que más se repita o, en caso de empate, la clase que corresponda al vecino más cercano.

En cada momento la distancia euclídea se calcula teniendo en cuenta las características que están seleccionadas en el momento, por lo que no podemos tener una matriz fija de distancias, hay que ir calculándolas sobre la marcha.

### 2.3. Función de evaluación

La función de evaluación será el rendimiento promedio de un clasificador 3NN en el conjunto de entrenamiento: calcularemos la tasa para cada dato dentro del conjunto de entrenamiento haciendo el leave one out descrito anteriormente y nos quedaremos con la media de las tasas obtenidas. El objetivo será por tanto maximizar esta función. La tasa se calcula como  $100 \cdot (\text{n}^\circ \text{ instancias bien clasificadas} / \text{n}^\circ \text{ total de instancias})$ .

El pseudo-código es el siguiente:

Se obtiene el subconjunto de entrenamiento que se va a tener en cuenta según las características que se estén considerando.

Para cada dato:

- Se saca **del** conjunto de entrenamiento (leave one out)

- Se calcula la tasa para este dato

- Se acumula la tasa al resto de tasas

Se divide la acumulación de tasas entre el cardinal **del** conjunto y lo se devuelve.

La función que hace esto la llamaremos `CalcularTasa(conjunto, características)` donde `características` es la máscara que nos indica cuáles estamos considerando (aquellas que estén a `True`).

## 2.4. Operadores comunes: Generación de vecinos

Se considerarán como vecinas todas aquellas soluciones que difieran en la pertenencia o no de una única característica (si se diferencian en más de una entonces no es vecina de la considerada). Por ejemplo, las soluciones `(True, True, False)` y `(True, False, False)` son vecinas porque se diferencian en una sola característica, la segunda.

`Flip` será el operador de vecino: recibe un vector de máscaras y una posición y cambia esa posición en el vector de máscaras.

### 3. Descripción de los algoritmos

#### 3.1. Búsqueda Local

El algoritmo de búsqueda local implementado ha sido el del primer mejor, es decir, exploramos los vecinos de la solución que tenemos en cada momento y en cuanto obtenemos una mejor nos quedamos con ella y empezamos a generar sus vecinos. Los vecinos se empiezan a generar por una característica aleatoria y a partir de esa característica se van cambiando las demás hasta el final y de nuevo por el principio hasta llegar a la primera que habíamos cambiado. Si no nos quedamos con la solución tenemos que dejar la característica que habíamos cambiado como estaba y si nos la quedamos dejamos de generar vecinos de la solución que teníamos y pasamos a generar vecinos de la nueva solución. El algoritmo para cuando da una pasada entera a los vecinos y no ha encontrado una mejor solución que la que tenía.

Veamos el pseudocódigo.

`generarSecuencia(tamaño)` será la función que empieza desde un número aleatorio (menor que el número de características) y de ahí en orden hasta el total de características y empieza de nuevo hasta el número que se ha generado al principio. Esta función nos dará el orden el que recorreremos los vecinos y la llamaremos cada vez que actualicemos la solución. Al algoritmo le pasamos como parámetros los datos de entrenamiento y las clases de los datos.

Empezar

```
caract = solución aleatoria inicial
tasa actual = calcularTasa(datos, caract)
```

```
while haya mejora en el vecindario y haya menos de 15000 evaluaciones
hacer:
```

```
    posiciones = generarSecuencia(tam(caract))
    for j en posiciones:
        Flip(caract, j) # Generamos vecino
        calcularTasa(caract)
        if la tasa del vecino es mejor que la actual:
            actualizamos la tasa actual
            vuelta_completa = False # hemos encontrado mejora antes de
            # generar todos los vecinos)
            break, salimos del bucle de dentro y empezamos a
            generar vecinos de la nueva solución

    else, volvemos a la antigua solución:
        Flip(caract, j)

    if vuelta_completa:
        no ha habido mejora en el vecindario, break
    else:
        vuelta_completa = True

    if hemos superado el numero de evaluaciones
```

**break** y salimos **del** bucle de dentro

Devuelve `caract` y `tasa` actual  
Fin

### 3.2. Enfriamiento Simulado

El esquema de enfriamiento que he utilizado ha sido el esquema de Cauchy modificado, en el que la temperatura inicial y la modificación en cada iteración del algoritmo se realiza de la siguiente forma:

```
Tf = 0.001, fi = 0.3, mu = 0.3
Tini = (mu*tasa_inicial)/(-np.log(fi))
beta = (Tini - Tf)/(M*Tini*Tf) #M depende del número de vecinos a generar
                                     #y del número de evaluaciones
Tk = Tk/(1+beta*Tk) #Al final del bucle de enfriamiento
```

El algoritmo de enfriamiento simulado intenta mejorar el problema de la búsqueda local de quedarse en el primer óptimo local que encuentra, aceptando para ello soluciones que pueden ser peores que la actual bajo algunas circunstancias, en concreto, la temperatura. Al iniciar el algoritmo la temperatura es más alta y se va reduciendo con las iteraciones: la idea es aceptar más soluciones peores que la actual cuanto mayor es la temperatura, es decir, al inicio del algoritmo, e ir aceptando menos progresivamente según la temperatura va bajando. Devolvemos la mejor solución encontrada en general a lo largo del algoritmo. Necesitamos para ello guardar la mejor solución junto con su tasa y la solución actual junto con su tasa.

En cada enfriamiento generamos vecinos hasta un máximo de forma aleatoria y nos la quedamos si es mejor que la actual o supera la probabilidad de aceptar una solución peor.

Con esto, el pseudocódigo es el siguiente:

```
Empezar
caract = solución aleatoria inicial
mejor solucion = caract
mejor tasa = calcularTasa(datos, caract)
Se calculan los parámetros para la temperatura y los vecinos totales
while haya éxitos en el enfriamiento actual y Tk>Tf y haya menos de 15000 evals:
    while no se haya generado el máximo de vecinos ni se sobrepasen los éxitos:
        pos = num aleatorio entre 0 y n #n num de características
        caract = Flip(caract, pos)
        nueva tasa = calcularTasa(datos, caract)
        Se aumenta num vecinos y num evaluaciones
        delta = nueva tasa - tasa actual
        if delta!=0 y (delta>0 o U(0,1)<=exp(delta/Tk)):
            #Se ha aceptado el vecino
            Se actualiza la tasa actual
            Se aumenta el número de éxitos
            if tasa actual > mejor tasa:
                Se actualizan la mejor solución y la mejor tasa
```

**else :**

*#No se ha aceptado el vecino, volvemos a la solución anterior*  
Flip(caract, pos)

Comprobamos si hemos pasado el número de evaluaciones  
**Fin del while** interior

Comprobamos si ha habido éxitos en este enfriamiento  
Ponemos el número de éxitos a 0  
Ponemos el número de vecinos a 0

Tk = Tk/(1+beta\*Tk) *#Actualizamos temperatura*  
**Fin del while** exterior

Devolvemos mejor solución y mejor tasa  
**Fin**

$U(0,1)$  es un número aleatorio extraído de la distribución uniforme en el intervalo  $[0,1]$ .

He tenido que poner como condición adicional en el **if** para aceptar una solución que  $\text{delta} \neq 0$  porque si las tasas son iguales y la diferencia es cero entonces la exponencial de  $\text{delta}/T_k$  es siempre 1 al ser delta 0 y un número entre 0 y 1 es siempre menor o igual que 1, con lo que siempre cogía como éxito una solución con la misma tasa, haciendo que el algoritmo tardara mucho más al haber siempre éxitos en el enfriamiento actual, cuando en realidad no se estaba moviendo ni hacia arriba ni hacia abajo.

### 3.3. Búsqueda Tabú Básica

En la búsqueda tabú también buscamos salir de óptimos locales con unos mecanismos distintos a los del enfriamiento simulado. En este caso vamos a tener almacenada una lista tabú que nos guarda las posiciones de las características que hemos cambiado en los  $n/3$  movimientos anteriores, donde  $n$  es el número de características. La lista tiene por tanto  $n/3$  posiciones y está implementada como una lista circular, de forma que tenemos un índice marcando la última posición añadida y el siguiente a ese índice módulo  $n/3$  es el próximo que tenemos que modificar. Se guardan estas posiciones para que no se pueda volver a cambiar una característica en esas posiciones para no volver hacia soluciones que habíamos considerado peores, a no ser que modificar una característica en la lista tabú mejore a la mejor solución que tenemos en ese momento. El método de búsqueda en este caso es la generación de 30 vecinos aleatorios de la solución actual y quedarnos con el mejor de ellos, sea mejor o no que el que teníamos. Guardamos siempre la mejor solución, que será la que se devolverá. Con esto, el pseudocódigo es el siguiente:

Empezar

caract = solución aleatoria inicial

mejor tasa = calcularTasa(datos, caract)

mejor solución = caract

lista tabú = vector de longitud  $n/3$  inicializado a  $-1$

plista =  $-1$  *#indica la última posición modificada en la lista*



```

while num evaluaciones < 15000:
    tasa actual = 0
    mejor pos = -1
    posiciones = 30 vecinos generados aleatoriamente
    for j en posiciones:
        caract = Flip(caract, j) #Generamos vecino
        nueva tasa = calcularTasa(datos, caract)
        Se aumenta el número de evaluaciones
        if j esta en la lista tabú:
            if nueva tasa > mejor tasa y nueva tasa > tasa actual:
                Se actualiza la tasa actual con la nueva
                Se cambia j como mejor posición
            elif nueva tasa > tasa actual:
                Se actualiza la tasa actual con la nueva
                Se cambia j como mejor posición
        # Volvemos a la solución que teníamos para seguir generando vecinos
        caract = Flip(datos, caract)

Fin for
# Nos quedamos con el mejor vecino
caract = Flip(caract, mejor pos)
plista = (plista+1)mod(n/3)
lista tabu[plista] = mejor pos

if tasa actual > mejor tasa:
    Se actualiza la mejor tasa y la mejor solución.

Fin while

Devuelve mejor solución y mejor pos
Fin

```

### 3.4. Búsqueda Tabú Extendida

La búsqueda tabú extendida utiliza el mismo mecanismo de memoria a corto plazo que la tabú sencilla, la lista tabú, aunque le iremos cambiando el tamaño. Incorpora además una memoria a largo plazo en la que se guarda el número de veces que se selecciona una característica para obtener la frecuencia de cada característica y si en algún momento se llega a 10 iteraciones sin mejora en la mejor solución, se reinicializa la búsqueda desde una nueva solución que tendrá probabilidad 0.25 de ser aleatoria, probabilidad 0.25 de ser la mejor solución y probabilidad 0.5 de ser generada de forma aleatoria utilizando el vector de frecuencias.

El pseudocódigo es el mismo que el de la búsqueda tabú sencilla con una modificación al final:

```

Empezar
... (igual que antes)

```

```

frec = vector de frecuencias de longitud n (num características)
inicializado a cero

while num evaluaciones < 15000:
    ... (igual que antes)
    for j en posiciones:
        ... (igual que antes)
    Fin for

    # Nos quedamos con el mejor vecino
    caract = Flip(caract, mejor pos)
    plista = (plista+1)mod(n/3)
    lista tabu[plista] = mejor pos
    Se aumenta frec[mejor pos] en 1

    if tasa actual > mejor tasa:
        Se actualiza la mejor tasa y la mejor solución.
        no_mejora = 0
    else:
        no_mejora += 1

    if no_mejora llega a 10:
        no_mejora = 0
        Se elige un numero entre 3 en el que los dos primeros tienen
        probabilidad 0.25 de aparecer y el tercero tiene 0.5
        if sale el primero:
            caract = solución aleatoria
        elif sale el segundo:
            caract = mejor solución
        else:
            u = número uniforme entre 0 y 1
            for i de 0 hasta n: # n num características
                if u < 1 - frec[i]:
                    se pone la característica i a True
                else
                    se pone a False
            u = número uniforme entre 0 y 1
            if u < 0.5
                Se aumenta al doble la lista tabú
            else:
                Se disminuye a la mitad la lista tabú

Fin while

Devuelve mejor solución y mejor pos
Fin

```

## 4. Breve descripción del algoritmo de comparación

El algoritmo de comparación seleccionado ha sido el greedy Sequential Forward Selection (SFS), que parte de una solución inicial en la que no hay ninguna característica seleccionada y se va quedando en cada iteración con la característica con la que se obtiene la mejor tasa. El algoritmo no para mientras se encuentre mejora añadiendo alguna característica.

He implementado una función que me devuelve, para una máscara determinada, la característica más prometedora que se puede obtener, cuyo pseudocódigo es el siguiente:

```
Empezar caractMasPrometedora(mascara):
    posiciones = posiciones que no estén seleccionadas de la mascara
    for i en posiciones:
        mascara[i] = True
        Se calcula la tasa con la nueva característica añadida
        if nueva tasa > mejor tasa:
            Se actualiza la mejor tasa
            Se actualiza la mejor posición
    Fin for
    Devuelve mejor tasa y mejor pos
Fin
```

Con esto, el pseudocódigo del algoritmo SFS es:

```
Empezar
caract = solución inicial inicializada a False
tasa actual = 0
mejora = True
while haya mejora:
    Se calcula la tasa y la mejor posición con caractMasPrometedora
    if nueva tasa > tasa actual:
        Se actualiza la tasa actual
        Se pone a True la característica en mejor posición
    else:
        mejora = False      #No ha habido mejora: paramos

Fin while

    Devuelve caract y tasa
Fin
```

## 5. Procedimiento considerado para desarrollar la práctica

## 6. Experimentos y análisis de resultados

### 6.1. Descripción de los casos del problema empleados

### 6.2. Resultados

Cuadro 1: Resultados SFS

	Wdbc				Movement Libras				Arrhythmia			
	%_clas train	%_clas test	%_red	T (s)	%_clas train	%_clas test	%_red	T (s)	%_clas train	%_clas test	%_red	T (s)
Partición 1-1	98,9437	93,3333	83,3333	47,7583	65,5556	64,4444	92,2222	128,1156	81,7708	70,1031	97,1223	474,7185
Partición 1-2	95,7895	94,0141	83,3333	47,5713	73,8889	70,0000	91,1111	141,5071	80,9278	78,6458	97,1223	474,0171
Partición 2-1	95,4225	93,3333	90,0000	32,6485	70,0000	70,5556	91,1111	141,5607	78,6458	70,1031	97,4820	417,5319
Partición 2-2	97,5439	94,3662	90,0000	32,8499	67,2222	66,1111	93,3333	110,7466	85,0515	70,8333	96,4029	582,5531
Partición 3-1	97,8873	96,4912	76,6667	61,5079	71,1111	70,0000	90,0000	159,5794	75,0000	69,0722	98,9209	209,9304
Partición 3-2	97,5439	93,6620	86,6667	40,9398	66,6667	70,0000	92,2222	127,1383	78,8660	71,3542	97,8417	365,9823
Partición 4-1	96,8310	97,8947	86,6667	39,8884	67,7778	70,5556	92,2222	128,9092	82,8125	73,7113	96,7626	526,7995
Partición 4-2	97,5439	95,4225	83,3333	46,9100	78,3333	62,2222	90,0000	157,2638	85,0515	73,4375	96,0432	632,3626
Partición 5-1	97,5352	95,7895	90,0000	32,3780	80,0000	62,2222	86,6667	204,0013	82,2917	68,0412	97,4820	424,4544
Partición 5-2	96,1404	94,7183	83,3333	47,9195	77,7778	68,8889	90,0000	159,4742	78,8660	72,3958	97,1223	485,9460
Media	97,1181	94,9025	85,3333	43,0372	71,8333	67,5000	90,8889	145,8296	80,9284	71,7698	97,2302	459,4296

Cuadro 2: Resultados BL

	Wdbc				Movement Libras				Arrhythmia			
	%_clas train	%_clas test	%_red	T (s)	%_clas train	%_clas test	%_red	T (s)	%_clas train	%_clas test	%_red	T (s)
Partición 1-1	97,5352	93,6842	46,6667	3,7190	62,2222	69,4444	52,2222	8,8476	68,2292	63,4021	50,3597	9,8135
Partición 1-2	94,3860	95,4225	46,6667	1,2674	69,4444	76,1111	46,6667	12,3067	67,0103	63,5417	45,3237	32,3330
Partición 2-1	95,7746	96,8421	63,3333	3,3681	67,7778	74,4444	57,7778	1,5256	65,6250	61,3402	56,1151	65,7732
Partición 2-2	96,4912	92,9577	46,6667	7,1604	65,5556	65,0000	56,6667	17,8602	68,0412	64,5833	46,4029	51,7505
Partición 3-1	96,1268	96,1404	33,3333	11,9843	67,7778	70,0000	56,6667	10,5577	66,6667	63,9175	46,4029	32,6144
Partición 3-2	96,4912	97,1831	43,3333	11,0846	66,6667	70,5556	50,0000	7,8249	67,5258	65,6250	52,5180	36,3594
Partición 4-1	96,1268	95,4386	40,0000	5,8840	59,4444	70,5556	53,3333	7,8953	67,1875	62,3711	43,8849	16,5154
Partición 4-2	95,7895	94,3662	63,3333	10,4619	72,2222	61,6667	44,4444	7,9087	65,9794	66,6667	52,8777	4,9554
Partición 5-1	96,1268	96,8421	46,6667	9,4036	71,1111	67,7778	53,3333	8,5307	65,1042	64,9485	48,9209	4,5913
Partición 5-2	97,5439	95,7746	50,0000	8,3311	71,1111	68,3333	51,1111	11,8468	63,9175	63,0208	46,0432	42,4668
Media	96,2392	95,4652	48,0000	7,2665	67,3333	69,3889	52,2222	9,5104	66,5287	63,9417	48,8849	29,7173

Cuadro 3: Resultados ES

	Wdbc				Movement Libras				Arrhythmia			
	%_clas train	%_clas test	%_red	T (s)	%_clas train	%_clas test	%_red	T (s)	%_clas train	%_clas test	%_red	T (s)
Partición 1-1	98,9437	95,0877	43,3333	190,6666	61,1111	68,3333	51,1111	383,7357	73,9583	62,3711	49,6403	1641,5006
Partición 1-2	95,7895	96,1268	46,6667	186,5556	70,0000	73,3333	55,5556	381,7689	70,1031	62,5000	50,0000	1663,5517
Partición 2-1	97,5352	95,7895	50,0000	185,7704	70,5556	75,5556	62,2222	383,1403	66,1458	61,8557	49,2806	1571,5591
Partición 2-2	98,2456	94,0141	53,3333	188,5999	66,6667	62,7778	44,4444	390,1831	70,1031	63,5417	51,0791	1562,8782
Partición 3-1	97,1831	95,0877	60,0000	185,9046	66,6667	72,2222	55,5556	384,5502	69,2708	65,4639	47,4820	1593,5539
Partición 3-2	97,8947	94,7183	46,6667	188,8094	68,8889	73,3333	53,3333	374,4300	70,6186	66,6667	53,5971	1536,6501
Partición 4-1	97,1831	96,8421	53,3333	197,0699	62,7778	76,1111	52,2222	379,0105	70,8333	64,9485	50,0000	1532,1212
Partición 4-2	96,8421	94,0141	36,6667	210,1286	73,3333	59,4444	55,5556	384,5273	69,5876	66,1458	47,1223	1599,9626
Partición 5-1	96,8310	96,8421	50,0000	195,4052	71,1111	66,6667	41,1111	391,5431	71,8750	64,9485	48,5612	1600,2462
Partición 5-2	97,5439	96,4789	53,3333	189,5962	72,2222	70,0000	48,8889	387,5911	68,0412	68,7500	50,3597	1555,9471
Media	97,3992	95,5001	49,3333	191,8507	68,3333	69,7778	52,0000	384,0480	70,0537	64,7192	49,7122	1585,7971

Cuadro 4: Resultados BT

	Wdbc				Movement Libras				Arrhythmia			
	%_clas train	%_clas test	%_red	T (s)	%_clas train	%_clas test	%_red	T (s)	%_clas train	%_clas test	%_red	T (s)
Partición 1-1	99,6479	94,0351	53,3333	4482,1553	71,1111	67,7778	67,7778	2792,4891	77,6042	64,9485	50,3597	3547,2839
Partición 1-2	97,8947	96,4789	40,0000	4525,3261	77,7778	71,1111	50,0000	2811,5240	72,1649	61,4583	54,3165	3689,6839
Partición 2-1	98,2394	96,8421	40,0000	4414,8685	77,7778	75,5556	51,1111	2816,0023	69,7917	62,8866	56,8345	3547,7961
Partición 2-2	99,6491	94,3662	50,0000	4387,6807	72,7778	65,5556	57,7778	2793,7549	78,8660	65,1042	56,4748	3540,1120
Partición 3-1	98,9437	94,3860	56,6667	4435,5301	75,5556	72,7778	58,8889	2804,0871	75,0000	65,9794	60,0719	3567,9060
Partición 3-2	98,5965	95,7746	63,3333	4402,7661	76,6667	70,5556	63,3333	2784,8322	75,7732	67,7083	56,4748	3516,0451
Partición 4-1	98,2394	96,1404	50,0000	4398,5370	72,2222	73,8889	56,6667	2817,5327	76,5625	65,9794	53,2374	3498,7134
Partición 4-2	98,5965	96,4789	63,3333	4400,6981	81,1111	62,2222	61,1111	2776,8963	72,1649	67,1875	51,0791	3538,5967
Partición 5-1	98,9437	96,4912	50,0000	4389,9218	79,4444	68,8889	62,2222	2802,4383	74,4792	65,4639	48,9209	3524,8939
Partición 5-2	98,9474	97,5352	43,3333	4422,8620	80,0000	68,3333	62,2222	2812,4940	74,2268	67,1875	56,8345	3471,6671
Media	98,7698	95,8529	51,0000	4426,0345	76,4444	69,6667	59,1111	2801,2051	74,6633	65,3904	54,4604	3544,2698

Cuadro 5: Resultados BTE

	Wdbc				Movement Libras				Arrhythmia			
	%_clas train	%_clas test	%_red	T (s)	%_clas train	%_clas test	%_red	T (s)	%_clas train	%_clas test	%_red	T (s)
Partición 1-1	99,2958	94,3860	53,3333	4891,4500	68,8889	67,2222	58,8888	3159,3639	75,0000	65,4639	52,1583	4398,2495
Partición 1-2	97,5439	96,8310	20,0000	4855,4829	75,5556	72,2222	46,6666	3183,8460	69,0722	63,0208	51,7986	4597,1095
Partición 2-1	97,8873	96,8421	30,0000	4932,8456	76,6667	76,6667	46,6666	3251,4145	70,8333	60,8247	44,2446	4412,4157
Partición 2-2	99,2982	93,6620	40,0000	4889,1054	70,0000	67,2222	50,0000	3174,5812	74,2268	67,7083	48,9209	4466,9630
Partición 3-1	98,9437	96,1404	33,3333	4874,8818	72,7778	70,5556	50,0000	3163,0693	75,0000	65,4639	52,5180	4320,1314
Partición 3-2	98,2456	96,1268	43,3333	4837,6802	73,3333	73,3333	45,5555	3183,1151	74,7423	67,7083	55,3957	4414,9784
Partición 4-1	97,8873	96,8421	40,0000	4682,4851	71,6667	77,7778	60,0000	3161,6695	73,4375	64,9485	44,2446	4255,8287
Partición 4-2	98,2456	97,8873	56,6667	4468,9579	81,1111	62,7778	62,2222	3134,6418	72,6804	66,6667	51,0791	4119,7669
Partición 5-1	98,2394	94,7368	53,3333	4478,3304	76,6667	67,7778	50,0000	3182,7247	70,8333	64,4330	48,5612	4185,7275
Partición 5-2	98,5965	97,1831	43,3333	4373,2153	80,0000	70,0000	58,8889	3164,9642	69,0722	65,1042	49,2806	4117,4000
Media	98,4183	96,0638	41,3333	4728,4435	74,6667	70,5556	52,8889	3175,9390	72,4898	65,1342	49,8201	4328,8571

### 6.3. Análisis de los resultados

## 7. Bibliografía